# L'IA ET CYBERSÉCURITÉ amul

**GROUPE 10** 

ALLOUI MOHAMED, BAUQUIN NIELS, DOUZI YOUSSEF, KALLEL MOHAMED ALI | MASTER INFORMATIQUE 2024/2025 SUPERVISÉ PAR : SCHATZ THOMAS



### Introduction

Cybersécurité : un enjeu clé à l'ère numérique :

- · Protège les systèmes, réseaux et données contre les cybermenaces. **Principaux objectifs:** · Confidentialité : garantir la sécurité des informations.
- · Intégrité : prévenir toute altération non autorisée des données.
- · Disponibilité: assurer un accès continu aux systèmes et services.
  - **Menaces courantes:**
  - Attaques par malware, ransomware et phishing.
  - · Exploitation des vulnérabilités des systèmes. **Défis actuels :**

· Complexité croissante des attaques.

• Besoin accru de solutions innovantes comme le NLP et le Federated Learning.

Cybersecurity Market	
Période d'étude	2019 - 2029
Taille du Marché (2024)	USD 234.01 Billion
Taille du Marché (2029)	USD 424.14 Billion
CAGR (2024 - 2029)	11.44%
Marché à la Croissance la Plus Rapide	Asie-Pacifique
Plus Grand Marché	Amérique du Nord
Concentration du Marché	Faible
Acteurs majeurs pro	ofpoint. NortonLifeLock
IBI	Microsoft McAfee
Source: Mordor Intelligence	

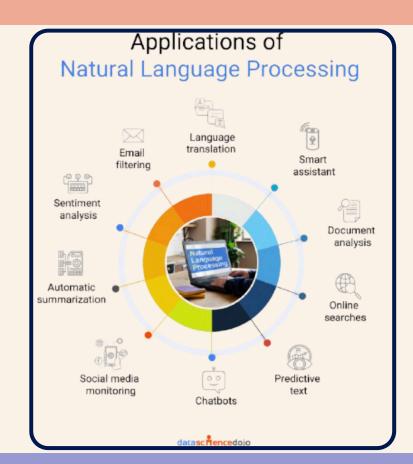
### Natural langage processing

#### Quoi:

Le Natural Language Processing (NLP), ou traitement automatique des langues, est un domaine de l'intelligence artificielle qui se concentre sur l'interaction entre les ordinateurs et le langage humain.

#### Pourquoi:

Permet aux machines de comprendre, d'analyser, de générer et d'interpréter le langage humain.



### Fonctionnement du NLP

#### **Collecte et nettoyage des données :**

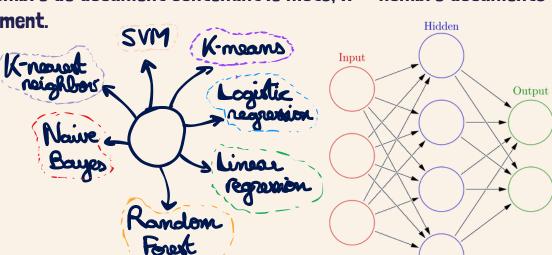
- Tokenisation : Division du texte en unités de base (mots, groupe de syllabes). Exemple : [ bonjour comment ça va ? 1 devient [ "Bonjour" , "comment" , "ça" , "va" , "?"]
- Suppression des Stop-words : Élimination des mots courants mais non affirmatifs ( LE , DE , ET , LA )
- Stemmatisation et Lemmatisation :
  - o Stemmatisation : Réduction d'un mot à sa racine, cette racine peut être fausse grammaticalement, le et faite par des algorithmes heuristiques en supprimant les préfixes et suffixes
  - o Lemmatisation : Méthode plus sophistiquée qui ramène un mot à son lemme, sa forme canonique. cette méthode se repose sur des règles linguistiques

Représentations des mots : Transformation des mots en une forme que les algorithmes de machine Learning peuvent comprendre : vecteurs numériques

- Bags of Word : chaque document est représenté par un vecteur de fréquence d'apparition des mots dans le document
- TF-IDF: Une amélioration de BoW qui pondère les mots en fonction de leur importance en appliquant la formule suivante:
  - TF-IDF = TF x log(N/DF) où DF = nombre de document contenant le mots, N = nombre documents TF= Fréquence du mot dans le document.

### **Traitement avec des modèles d'IA:**

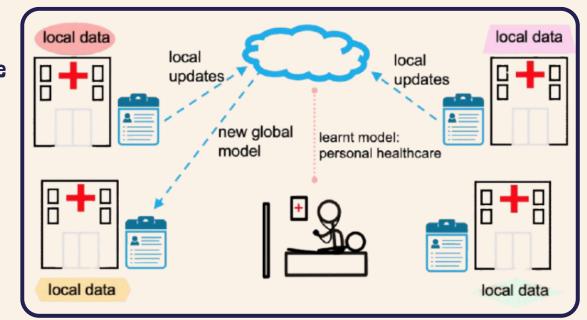
- Approches classiques :
  - Régressions (Linéaire, Logistique)
  - Modèles probabilistes (Naïf Bayes)
  - SVM
- Approches modernes :
  - Transformers (Bert, GPT)
  - RNN (Recurrent neural Networks)



### Le Federated Learning

#### **Définition:**

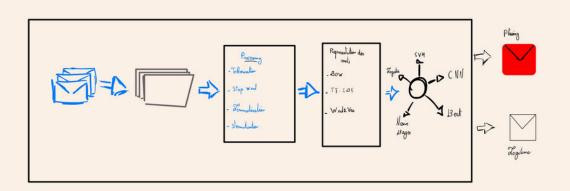
Le Federated Learning (apprentissage fédédré) est une technique d'apprentissage machine où les données restent sur les appareils locaux, et seuls les modèles ou les mises à jour des paramètres sont partagés



#### **Avantages pour la cybersécurité :**

- Protection de la vie privée en minimisant le transfert de données sensibles.
- Le système est plus résilient face aux attaques par déni de service (DDoS) ou par ransomware, qui ciblent souvent les bases de données centralisées.
- Les appareils connectés (comme les smartphones, les IoT) peuvent détecter des schémas malveillants localement et contribuer à améliorer un modèle global sans partager directement les logs sensibles. Cela permet de détecter les menaces émergentes rapidement, tout en maintenant un haut niveau de sécurité.
- Les mises à jour des modèles sont agrégées et chiffrées, ce qui limite les possibilités pour un acteur malveillant d'interférer ou d'accéder aux données.

### Application à la cyber-sécurité : Pishing détection



L'IA repose sur les données. Par conséquent, utiliser l'IA pour se protéger nous amène à réfléchir à la manière de sécuriser ces données.

## Les risques de securité

### Data poisoning attacks:

- Un participant malveillant modifie ou insère des données incorrectes, biaisées ou malveillantes dans son propre ensemble d'entraînement.
- Les modèles locaux formés avec ces données biaisées introduisent des erreurs dans le modèle global après agrégation.



### **Model poisoning attacks:**

- Un participant compromis entraîne localement un modèle avec des objectifs malveillants.
- Lors de l'étape d'agrégation, il envoie des mises à jour modifiées au serveur.
- Le serveur, en intégrant ces mises à jour, adopte progressivement des comportements indésirables.

### Conclusion

### L'intelligence artificielle transforme la cybersécurité :

- Détection avancée des menaces.
- Analyse prédictive performante.
- · Automatisation des réponses. • Défis liés à la centralisation des données :
  - Vulnérabilité accrue aux cyberattaques.
- Problèmes de confidentialité et enjeux éthiques.

### Le Federated Learning combine l'efficacité de l'IA et des modèles décentralisés :

· Réduction des risques liés à la concentration des données.

### **Federated Learning: une** alternative prometteuse mais imparfaite

- Réduit les risques liés à la centralisation des données.
  - Reste vulnérable à des attaques spécifiques :
- Data poisoning: contamination des données d'apprentissage.
- Model poisoning: altération des modèles d'IA.

### **Conclusion : un champ encore** en évolution

· Les défis en matière de résilience et d'efficacité de l'IA en cybersécurité restent nombreux.

 Nécessité de développer des solutions complémentaires pour renforcer la sécurité.



- Priyanka Mary Mammen. (2021). Federated Learning: Opportunities and Challenges. **University of Massachusetts.**
- Iqbal H. Sarker. Al-Driven Cybersecurity: An Overview, Security Intelligence Modeling and **Research Directions.**
- Joseph Nnaemeka Chukwunweike, Moshood Yussuf, Oluwatobiloba Okusi. The role of deep learning in ensuring privacy integrity and security: Applications in Al-driven cybersecurity solutions.
- Bibhu Dash, Meraj Farheen Ansari, Pawankumar Sharma and Azad Ali. THREATS AND OPPORTUNITIES WITH AIBASED CYBER SECURITY INTRUSION DETECTION: A REVIEWDept. of Computer and Information Systems, University of the Cumberlands, Williamsburg, KY USA. 1
- JOON-WOO LEE, WOOSUK CHOI, JIEUN EOM. Privacy Preserving Machine Learning With Fully Homomorphic Encryption for Deep Neural NetworkDept. of Computer and Information Systems, University of the Cumberlands, Williamsburg, KY USA.
- Phishing Detection Using Natural Language Processing and Machine Learning Apurv Mittal
- Qu'est-ce que le PNL (Traitement du Langage Naturel) ? IBM technology
- The Role of Artificial Intelligence in Cyber-Defence AI Cybersecurity Vincent Lenders
- Entretien avec Mr. Nasraoui (ingénieur en cybersécurité)
- Natural Language Processing, Jacob Eisenstein